

Modelo de regresión múltiple

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_K X_K + \varepsilon$$

K = número de variables.

De forma extendida:

$$y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_K X_{iK} + \varepsilon_i$$

$i = 1, 2, \dots, n$ n = número de observaciones

Matricialmente

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad , \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix} \quad , \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$X = \begin{bmatrix} 1 & X_{11} & X_{12} & X_{13} & \dots & X_{1K} \\ 1 & X_{21} & X_{22} & X_{23} & \dots & X_{2K} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & X_{n3} & \dots & X_{nK} \end{bmatrix}$$

Así

$$\underline{\underline{Y = X\beta + \varepsilon}}$$

Definamos el modelo ajustado

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}$$

y el error

$$\hat{u}_i = y_i - \hat{y}_i; \left[\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \hat{u}_i^2 = S \right]$$

Se puede ver como

$$S = \hat{u}^t \hat{u} = [\hat{u}_1 \ \hat{u}_2 \ \dots \ \hat{u}_n] \begin{bmatrix} \hat{u}_1 \\ \hat{u}_2 \\ \vdots \\ \hat{u}_n \end{bmatrix}$$

Recordando que el modelo ajustado también se ve como:

$$\hat{y} = X \hat{\beta}$$

Entonces

$$\begin{aligned} S &= (y - X \hat{\beta})^t (y - X \hat{\beta}) \\ &= y^t y - \hat{\beta}^t x^t y - y^t X \hat{\beta} + \hat{\beta}^t x^t X \hat{\beta} \\ &= y^t y - 2 \hat{\beta}^t x^t y + \hat{\beta}^t x^t X \hat{\beta} \end{aligned}$$

De cálculo

$$\min S \Rightarrow \frac{\partial S}{\partial \hat{\beta}} = -2 x^t y + 2 x^t X \hat{\beta} = 0$$

Por lo tanto debe resolverse

$$x^t X \hat{\beta} = x^t y$$

Recordemos

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$$

Cuyo modelo ajustar es

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}$$

Sea

$$\hat{u}_i = y_i - \hat{y}_i \Rightarrow \min \sum_{i=1}^n \hat{u}_i^2 \quad \text{ó} \quad \min \sum_{i=1}^n SEC$$

$$\Rightarrow \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}))^2$$

De esta forma minimizando

$$\frac{\partial SEC}{\partial \hat{\beta}_j} = 0 \quad j = 1, 2, \dots, k$$

$$\frac{\partial SEC}{\partial \hat{\beta}_0} = 2 \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik})) (-1)$$

$$\frac{\partial SEC}{\partial \hat{\beta}_1} = 2 \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik})) (-x_{i1})$$

$$\frac{\partial SEC}{\partial \hat{\beta}_2} = 2 \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik})) (-x_{i2})$$

$$\vdots$$

$$\frac{\partial SEC}{\partial \hat{\beta}_k} = 2 \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik})) (-x_{ik})$$

Ahora

$$\frac{\partial \text{Sec}}{\partial \beta_j} = 0 \quad j = 0, 1, 2, \dots, k$$

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{\beta}_0 + \sum_{i=1}^n x_{i1} \hat{\beta}_1 + \sum_{i=1}^n x_{i2} \hat{\beta}_2 + \sum_{i=1}^n x_{i3} \hat{\beta}_3 + \dots + \sum_{i=1}^n x_{ik} \hat{\beta}_k$$

$$\sum_{i=1}^n x_{i1} y_i = \sum_{i=1}^n x_{i1} \hat{\beta}_0 + \sum_{i=1}^n x_{i1}^2 \hat{\beta}_1 + \sum_{i=1}^n x_{i1} x_{i2} \hat{\beta}_2 + \sum_{i=1}^n x_{i1} x_{i3} \hat{\beta}_3 + \dots + \sum_{i=1}^n x_{i1} x_{ik} \hat{\beta}_k$$

$$\sum_{i=1}^n x_{i2} y_i = \sum_{i=1}^n x_{i2} \hat{\beta}_0 + \sum_{i=1}^n x_{i1} x_{i2} \hat{\beta}_1 + \sum_{i=1}^n x_{i2}^2 \hat{\beta}_2 + \sum_{i=1}^n x_{i2} x_{i3} \hat{\beta}_3 + \dots + \sum_{i=1}^n x_{i2} x_{ik} \hat{\beta}_k$$

$$\sum_{i=1}^n x_{i3} y_i = \sum_{i=1}^n x_{i3} \hat{\beta}_0 + \sum_{i=1}^n x_{i1} x_{i3} \hat{\beta}_1 + \sum_{i=1}^n x_{i2} x_{i3} \hat{\beta}_2 + \sum_{i=1}^n x_{i3}^2 \hat{\beta}_3 + \dots + \sum_{i=1}^n x_{i3} x_{ik} \hat{\beta}_k$$

⋮

$$\sum_{i=1}^n x_{ik} y_i = \sum_{i=1}^n x_{ik} \hat{\beta}_0 + \sum_{i=1}^n x_{i1} x_{ik} \hat{\beta}_1 + \sum_{i=1}^n x_{i2} x_{ik} \hat{\beta}_2 + \sum_{i=1}^n x_{i3} x_{ik} \hat{\beta}_3 + \dots + \sum_{i=1}^n x_{ik}^2 \hat{\beta}_k$$

Notemos

$$\underbrace{\begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1} y_i \\ \sum_{i=1}^n x_{i2} y_i \\ \sum_{i=1}^n x_{i3} y_i \\ \vdots \\ \sum_{i=1}^n x_{ik} y_i \end{bmatrix}}_{X^t Y} = \underbrace{\begin{bmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i3} & \dots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1} x_{i2} & \sum_{i=1}^n x_{i1} x_{i3} & \dots & \sum_{i=1}^n x_{i1} x_{ik} \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i1} x_{i2} & \sum_{i=1}^n x_{i2}^2 & \sum_{i=1}^n x_{i2} x_{i3} & \dots & \sum_{i=1}^n x_{i2} x_{ik} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{i1} x_{ik} & \sum_{i=1}^n x_{i2} x_{ik} & \sum_{i=1}^n x_{i3} x_{ik} & \dots & \sum_{i=1}^n x_{ik}^2 \end{bmatrix}}_{X^t X} \underbrace{\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{bmatrix}}_{\hat{\beta}}$$

Por propiedades de matrices

$$[X^t X \hat{\beta} = X^t y] (X^t X)^{-1}$$

$$\hat{\beta} = (X^t X)^{-1} X^t y$$

Mostrando que $E[\hat{\beta}] = \beta$

$$E[\hat{\beta}] = E[(X^t X)^{-1} X^t y]$$

$$= E[(X^t X)^{-1} X^t [X\beta + \varepsilon]]$$

$$= E[\underbrace{(X^t X)^{-1} X^t X}_{I} \beta + (X^t X)^{-1} X^t \varepsilon]$$

I = matriz identidad

$$= E[I\beta + (X^t X)^{-1} X^t \varepsilon]$$

$$= E[I\beta] + E[(X^t X)^{-1} X^t \varepsilon]$$

$$= E[\beta] + (X^t X)^{-1} X^t E[\varepsilon]; E[\varepsilon] = 0$$

β = constantes

$$\underline{\underline{E[\hat{\beta}] = \beta}}$$

Para probar $\text{VAR}(\hat{\beta})$. Recordemos que, para una variable aleatoria

$$\text{VAR}(X) = E[(X - E[X])^2],$$

$$E[\hat{\beta}] = \beta$$

$$\begin{aligned}\text{VAR}(\hat{\beta}) &= E[(\hat{\beta} - \beta)^2] \\ &= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)]\end{aligned}$$

Recordemos

$$\hat{\beta} = (X^t X)^{-1} X^t Y$$

$$\hat{\beta} = (X^t X)^{-1} X^t [X\beta + \varepsilon]$$

$$\hat{\beta} = \underbrace{(X^t X)^{-1} X^t X}_{I} \beta + (X^t X)^{-1} X^t \varepsilon$$

$$\hat{\beta} = \beta + (X^t X)^{-1} X^t \varepsilon$$

$$\hat{\beta} - \beta = (X^t X)^{-1} X^t \varepsilon, \text{ de este modo}$$

$$\begin{aligned}\text{VAR}(\hat{\beta}) &= E[(X^t X)^{-1} X^t \varepsilon \varepsilon^t (X^t X)^{-1}] \\ &= E[\underbrace{(X^t X)^{-1} X^t}_{I} \varepsilon \varepsilon^t (X^t X)^{-1}] \\ &= E[I \varepsilon \varepsilon^t (X^t X)^{-1}]\end{aligned}$$

$$\text{VAR}(\hat{\beta}) = (X^t X)^{-1} E(\varepsilon \varepsilon^t)$$

Recordemos

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$$E[\varepsilon \varepsilon^t] = E \left[\begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix} [\varepsilon_1 \ \varepsilon_2 \ \dots \ \varepsilon_n] \right]$$

$$= E \begin{bmatrix} \varepsilon_1 \varepsilon_1 & \varepsilon_1 \varepsilon_2 & \varepsilon_1 \varepsilon_3 & \dots & \varepsilon_1 \varepsilon_n \\ \varepsilon_2 \varepsilon_1 & \varepsilon_2 \varepsilon_2 & \cdot & \cdot & \cdot & \varepsilon_2 \varepsilon_n \\ \varepsilon_3 \varepsilon_1 & \cdot & \varepsilon_3 \varepsilon_3 & \cdot & \cdot & \cdot \\ \vdots & \cdot & \cdot & \cdot & \cdot & \cdot \\ \varepsilon_n \varepsilon_1 & \varepsilon_n \varepsilon_2 & \cdot & \cdot & \cdot & \varepsilon_n \varepsilon_n \end{bmatrix}$$

Si las variables son independientes e idénticamente distribuidas

$$E[\varepsilon_i \varepsilon_j] = 0 \quad \text{para toda } i \neq j, \text{ de esta forma}$$

$$E[\varepsilon] = 0 \quad \text{y} \quad \text{VAR}[\varepsilon] = E[(\varepsilon - 0)^2] = E[\varepsilon^2] = \sigma^2$$

$$E[\varepsilon \varepsilon^t] = \begin{bmatrix} \sigma^2 & 0 & 0 & \dots & 0 \\ 0 & \sigma^2 & \cdot & \cdot & \cdot \\ 0 & \cdot & \sigma^2 & \cdot & \cdot \\ \vdots & \cdot & \cdot & \cdot & \cdot \\ 0 & \cdot & \cdot & \cdot & \sigma^2 \end{bmatrix} = \sigma^2 I$$

Por lo tanto

$$\text{VAR}(\hat{\beta}) = \sigma^2 (X^t X)^{-1}$$

Supuestos de regresión lineal múltiple

1) Lineal en los parámetros: el modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

donde $\beta_0, \beta_1, \dots, \beta_k$ son los parámetros (constantes) desconocidos de interés y u es un error aleatorio no observable o término de perturbación

2) Muestreo aleatorio

Se tiene una muestra aleatoria de n observaciones $\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i) : i=1, 2, \dots, n\}$ que satisface el primer supuesto. Nos dice además que se tienen datos que pueden emplearse para estimar los β_j y que estos datos han sido elegidos de manera que sean representativos de la población.

3) Colinealidad no perfecta.

En la muestra ninguna de las variables independientes es constante y no hay relación lineal constante entre las variables independientes

Si en cada variable independiente hay variaciones muestrales y no existe una relación lineal exacta entre las variables independientes, β_j se calculan (se pide)

4) Media condicional cero

El error u tiene un valor esperado de cero. Es decir,

$$E[u | x_1, x_2, \dots, x_k] = 0.$$

Si se cumple este supuesto los estimadores serán insesgados es decir

$$E[\hat{\beta}] = \beta$$

5) Homocedasticidad

Para cualesquiera valores de las variables explicativas, el error u tiene la misma variancia

$$\text{VAR}(u | x_1, x_2, \dots, x_k) = \sigma^2$$

Este supuesto no tiene relación con el sesgamiento de $\hat{\beta}_j$, sin embargo

1) permite obtener formulas para la variancia de muestreo (cuya componente son faciles de caracterizar)

2) Bajo los supuestos de Gauss-Markov los estimadores son los que tienen menor variancia entre todos los estimadores lineales insesgados.

6) Normalidad

El error poblacional u es independiente de las variables explicativas x_1, x_2, \dots, x_k y esta distribuido normalmente con media cero y

varianza σ^2 : es decir

$$\underline{u \sim \text{Normal}(0, \sigma^2)}$$

Para la matriz de variancia covarianza, se deben cumplir.

$$E[\varepsilon_j] = 0 \rightarrow \text{media cero para toda } j=1, 2, \dots, i$$

$$E[\varepsilon_i \varepsilon_j] = 0 \rightarrow \text{para toda } i \neq j$$

$$\text{VAR}(\varepsilon_j) = \sigma^2 \Rightarrow E[(\varepsilon - E[\varepsilon])'] = E[(\varepsilon - 0)'] = E[\varepsilon'] = \sigma^2$$

S. se cumplen estos supuestos los estimadores son insesgados y eficientes /