Análisis de BJsales

Contents

Información de contacto

Mail: alejandro.zavala1001@gmail.com

Facebook: https://www.facebook.com/AlejandroZavala1001

Git: https://github.com/AlejandroZavala98

```
## Loading required package: zoo

##
## Attaching package: 'zoo'

## The following objects are masked from 'package:base':
##
##     as.Date, as.Date.numeric

## Loading required package: MASS

## Warning: package 'forecast' was built under R version 4.1.1

## Registered S3 method overwritten by 'quantmod':
##   method            from
##   as.zoo.data.frame zoo

##
## Attaching package: 'forecast'

## The following object is masked from 'package:astsa':
##
##     gas
```

Modelando la serie BJsales

Descripción

Se vera el modelado de la serie temporal titulada 'BJsales'

> "La serie temporal de ventas BJsales y el indicador adelantado BJsales.lead contienen 150 observaciones."

Visualización

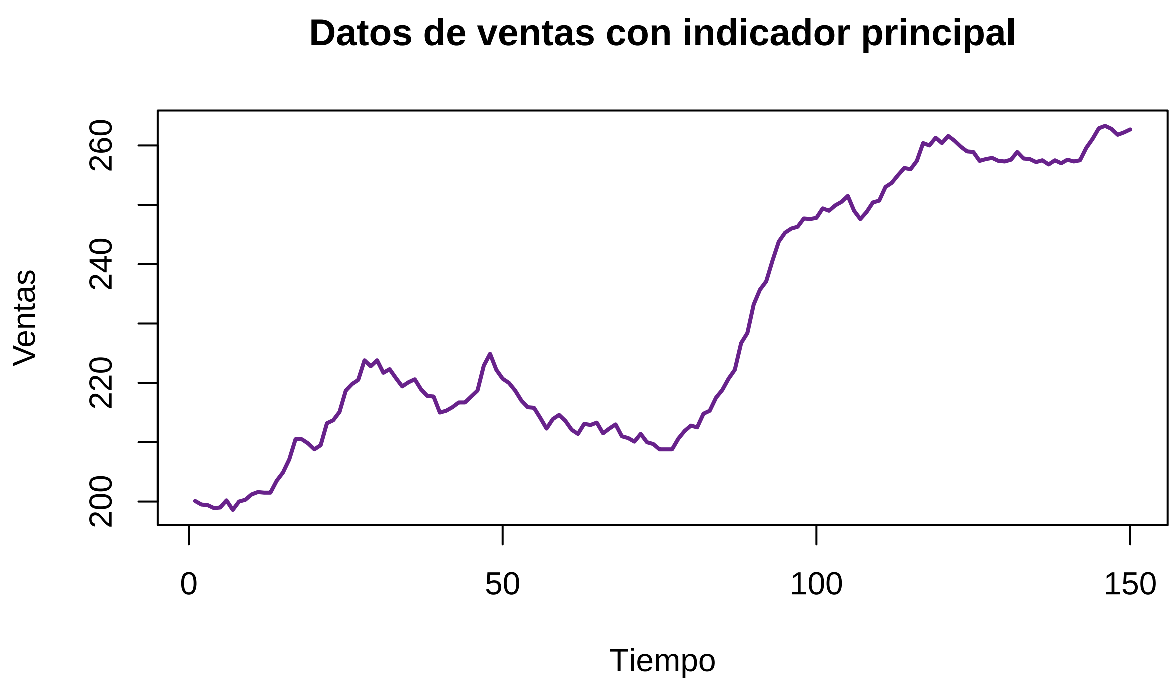

De la visualización anterior podemos mencionar:

1. Subidas y bajadas no constantes, con una tendencia en general al alza (creciendo)
2. La serie de tiempo no es estacionaria.

Obteniendo primera diferencia

Si a la serie original le aplicamos la primera diferencia podriamos hacerla estacionaria de tal forma

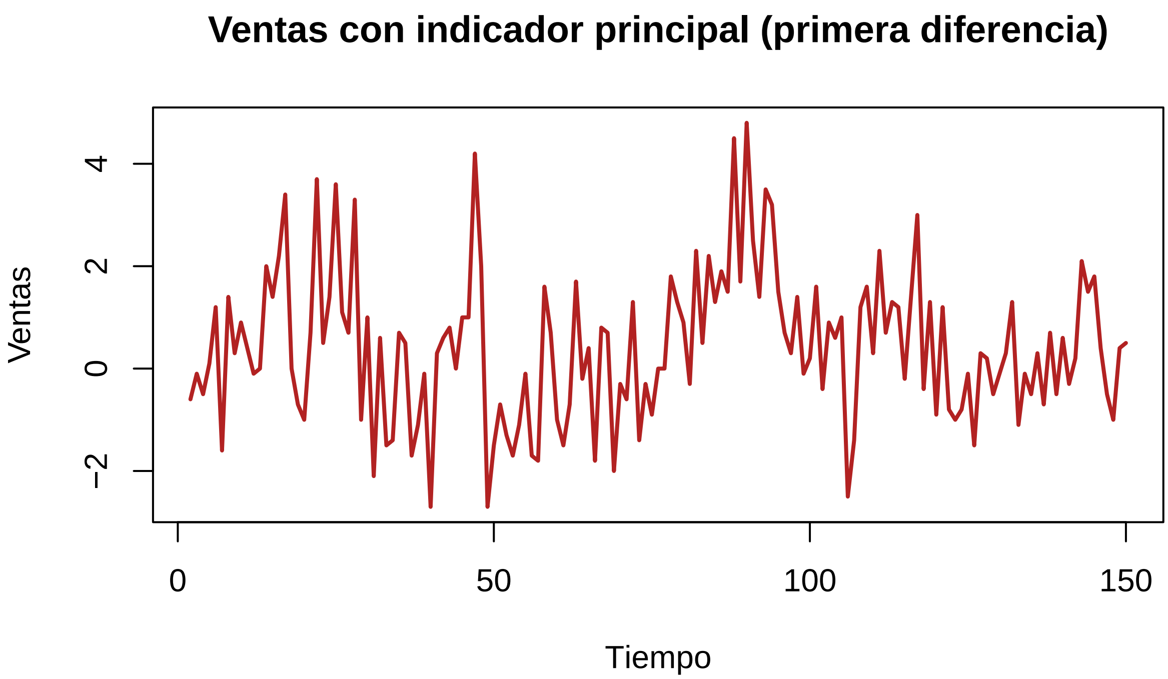

De esta manera podemos decir que: no parece estar estacionario ya que todavía hay tendencias al alza como a la baja en diferentes partes del gráfico de tiempo.

Obteniendo segunda diferencia

Veamos si con la segunda diferencia podemos hacerla estacionaria

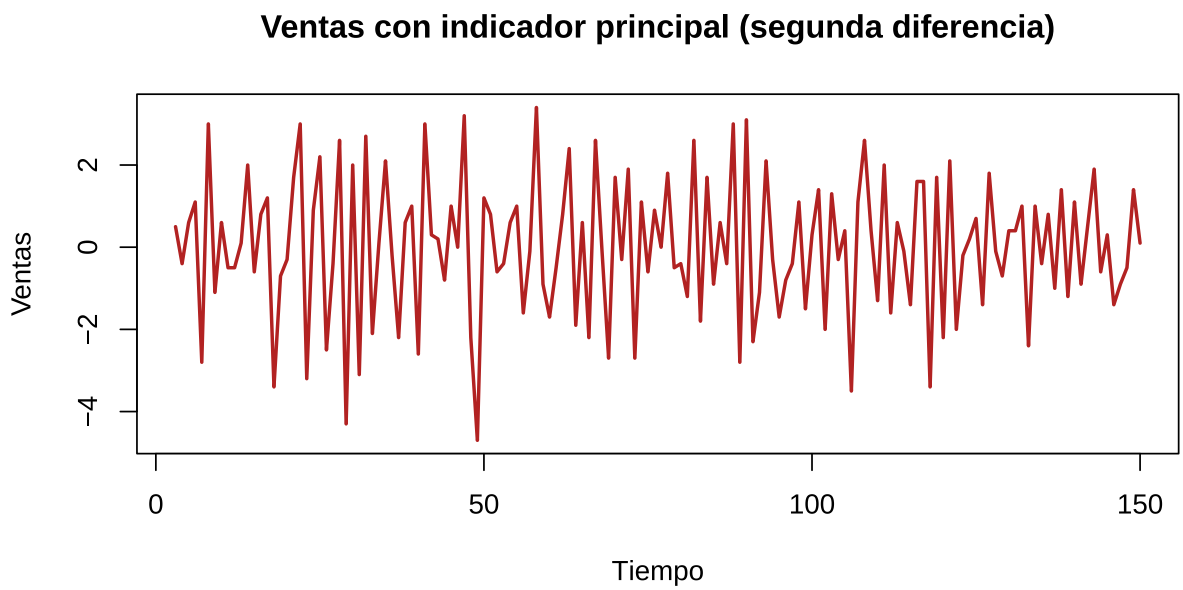

Con esta segunda diferencia observando la visualización podemos ver:

1. La variacion en los ultimos tiempos (a criterio propio a partir del tiempo 120) parece ser diferente en otras partes de la serie de tiempo.
2. No hay un cambio sistemático en la media, parece ser constantes alrededor de 0

PACF

Observando algunos valores de la PACF

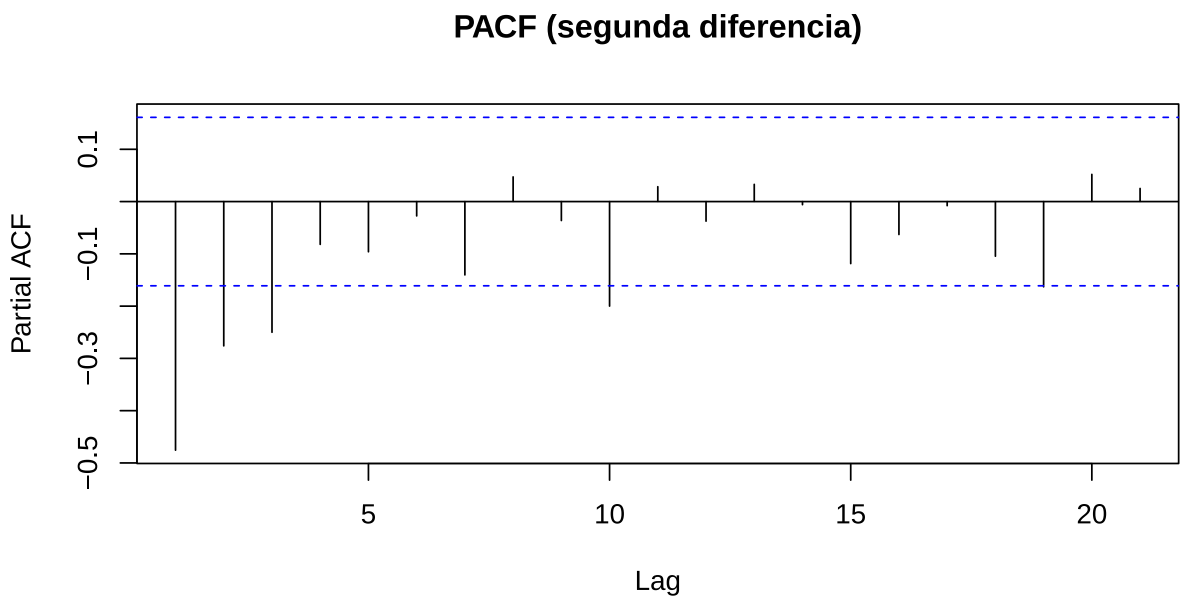


```
##
## Partial autocorrelations of series 'segunda_diff', by lag
##
##      1      2      3      4      5      6      7      8      9     10     11
## -0.476 -0.276 -0.250 -0.082 -0.096 -0.027 -0.140  0.047 -0.036 -0.200  0.028
##     12     13     14     15     16     17     18     19     20     21
## -0.037  0.033 -0.006 -0.119 -0.063 -0.008 -0.105 -0.163  0.052  0.025
```

De esta manera vemos que a los valores de la funcion de autocorrelacion parcial nos dice algunos rezagos importantes los cuales podrian ser:

- Rezago 1
- Rezago 2
- Rezago 3
- Rezago 10
- Rezago 19

ACF

Observando algunos valores de la ACF

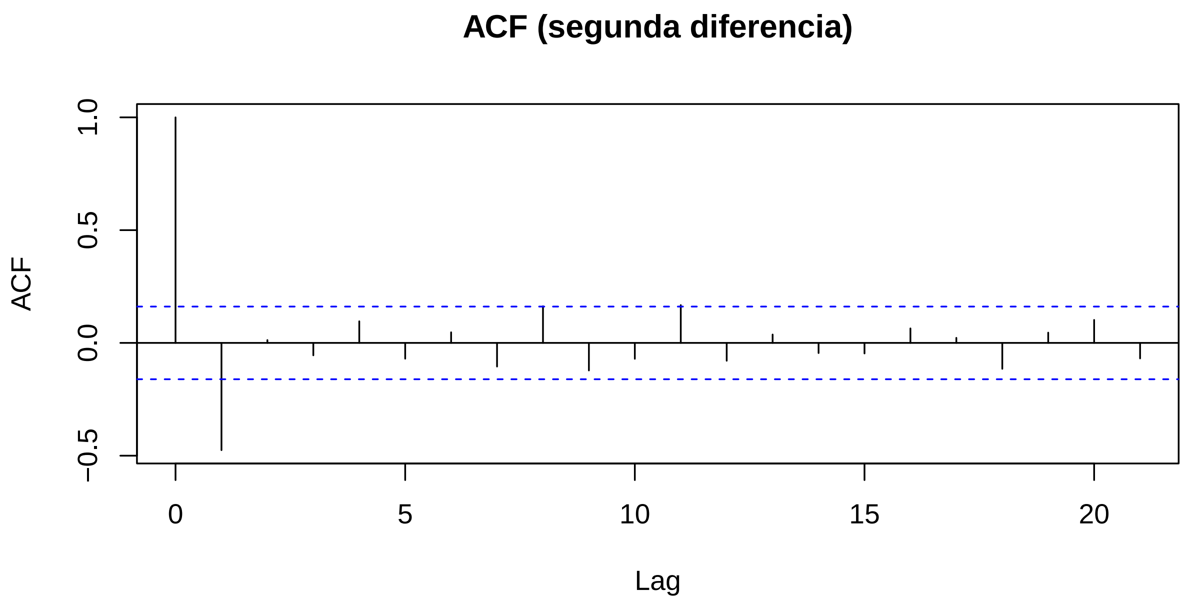


```
##
## Autocorrelations of series 'segunda_diff', by lag
##
##      0      1      2      3      4      5      6      7      8      9     10
##  1.000 -0.476  0.013 -0.055  0.096 -0.070  0.047 -0.105  0.163 -0.122 -0.071
##     11     12     13     14     15     16     17     18     19     20     21
##  0.168 -0.079  0.037 -0.045 -0.047  0.064  0.022 -0.115  0.046  0.102 -0.069
```

De esta manera vemos que a los valores de la funcion de autocorrelación nos dice algunos rezagos importantes los cuales podrian ser:

- Rezago 1
- Rezago 8
- Rezago 11

Comparación con modelos AIC

Dado los criterios obtenidos por la ACF y la PACF y tratando de obtener un modelo mas simple podemos ver con diferentes modelos

```
## Modelo ( 0 2 0 ) AIC= 577.6777  SSE= 423.7908  p-VALUE= 7.610494e-07
## Modelo ( 0 2 1 ) AIC= 517.1371  SSE= 276.2293  p-VALUE= 0.9632467
## Modelo ( 1 2 0 ) AIC= 541.9646  SSE= 327.92  p-VALUE= 0.003606979
## Modelo ( 1 2 1 ) AIC= 518.9734  SSE= 275.8554  p-VALUE= 0.941776
## Modelo ( 2 2 0 ) AIC= 532.2986  SSE= 302.7467  p-VALUE= 0.05824473
```

De este modo observamos que el criterio AIC mas bajo es el de orden (0,2,1) con 517.1371. Con un p-valor de 0.9632467. Con este p-valor no se rechaza la hipotesis nula (coeficientes de correlacion son cero)

Comparación con SSE Suma de errores al cuadrado (por sus siglas en ingles)

```
## Modelo ( 0 2 0 ) AIC= 577.6777  SSE= 423.7908  p-VALUE= 7.610494e-07
## Modelo ( 0 2 1 ) AIC= 517.1371  SSE= 276.2293  p-VALUE= 0.9632467
## Modelo ( 1 2 0 ) AIC= 541.9646  SSE= 327.92  p-VALUE= 0.003606979
## Modelo ( 1 2 1 ) AIC= 518.9734  SSE= 275.8554  p-VALUE= 0.941776
## Modelo ( 2 2 0 ) AIC= 532.2986  SSE= 302.7467  p-VALUE= 0.05824473
## Modelo ( 2 2 1 ) AIC= 520.2684  SSE= 274.0474  p-VALUE= 0.795544
## Modelo ( 3 2 0 ) AIC= 524.7648  SSE= 283.4941  p-VALUE= 0.7035291
## Modelo ( 3 2 1 ) AIC= 519.4182  SSE= 264.0684  p-VALUE= 0.6948066
```

Ahora si tomamos el valor mas pequeño de la SSE el modelo mejor seria el modelo (3,2,1)

Ajustando modelo ARIMA(0,2,1)

Si ajustamos los datos al modelo ARIMA(0,2,1)

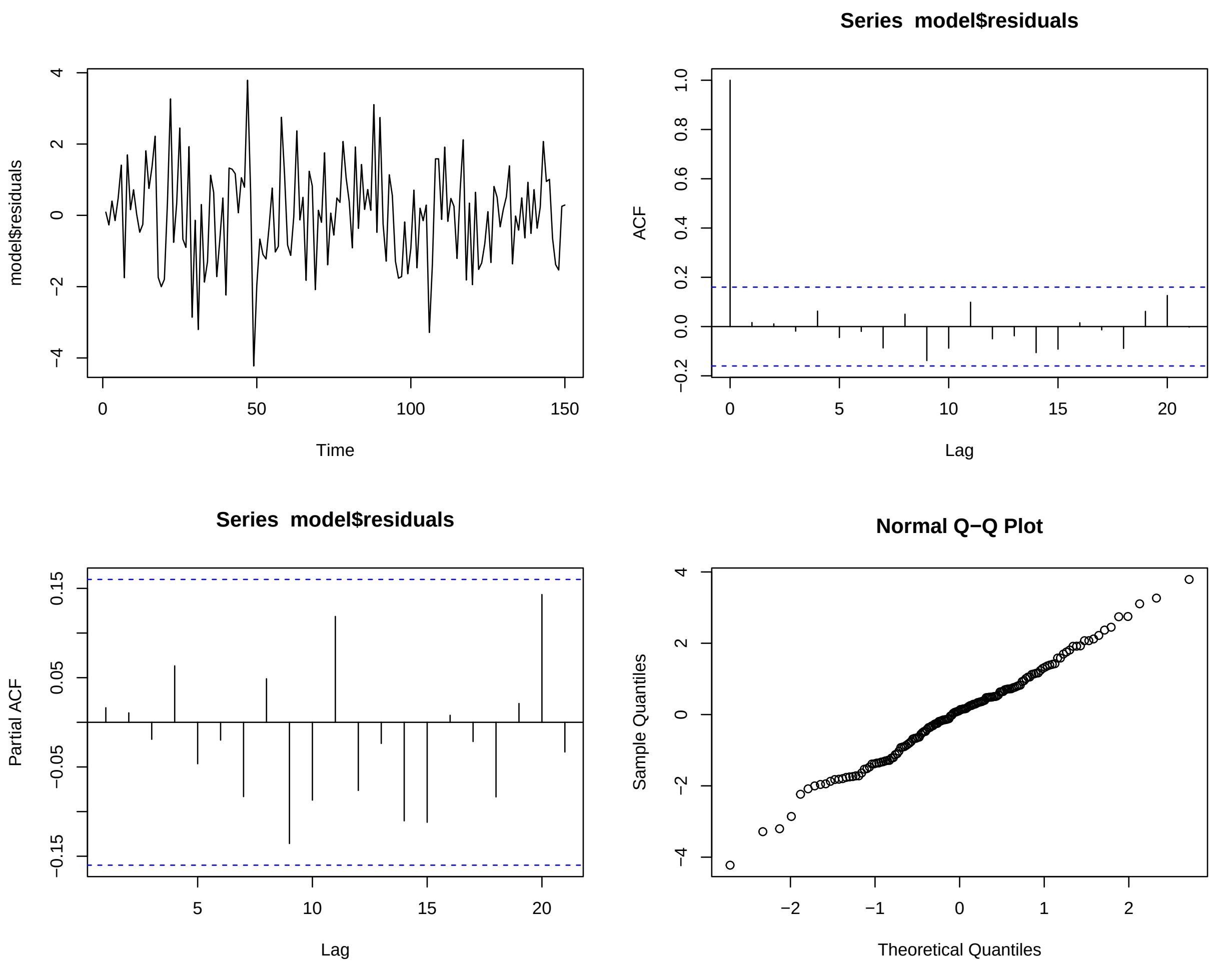

El grafico QQ-plot parece comportarse linealmente, y tanto ACF como PACF parecen no tener rezagos significantes

Ecuación del modelo Y_t

```
##
## Call:
## arima(x = BJsales, order = c(0, 2, 1), include.mean = TRUE)
##
## Coefficients:
##           ma1
##       -0.7480
## s.e.   0.0662
##
## sigma^2 estimated as 1.866:  log likelihood = -256.57,  aic = 517.14
```

De esta forma si denotamos

$$\begin{aligned} X_t &= BJsales \\ Y_t &= diff(diff(BJsales)) \end{aligned}$$

Quedando finalmente

$$\begin{aligned} Y_t &= Z_t - 0.748Z_{t-1} \\ Z &\sim N(0, 1.866) \end{aligned}$$

Ecuación del modelo X_t

De lo anterior podemos decir que el modelo es

$$\begin{aligned} X_t &= 2X_{t-1} - X_{t-2} + Z_t - 0.748Z_{t-1} \\ Z &\sim N(0, 1.866) \end{aligned}$$